



Universidad del Valle de Guatemala  
Facultad de Ingeniería  
Departamento de Ciencias de la Computación  
CC3084 — Data Science — Semestre II, 2026

---

# Laboratorio 1

## Series de Tiempo

Ingreso de viajeros internacionales a Guatemala  
enero 2009 — junio 2026

---

## **Integrantes**

Rodrigo Ajmac — 22279

Andrés Mazariegos — 21749

June Herrera — 231038

Guatemala, 26 de julio de 2026

# Índice general

|          |                                                                       |           |
|----------|-----------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introducción y datos</b>                                           | <b>3</b>  |
| 1.1      | Dos quiebres metodológicos que condicionan todo el análisis . . . . . | 3         |
| <b>2</b> | <b>Análisis exploratorio (punto 1)</b>                                | <b>4</b>  |
| 2.1      | Calidad de los datos: faltantes, duplicados y atípicos . . . . .      | 4         |
| 2.2      | Comportamiento temporal . . . . .                                     | 5         |
| 2.3      | Impacto y recuperación de la pandemia . . . . .                       | 6         |
| 2.4      | Países, regiones, vías y fronteras . . . . .                          | 7         |
| 2.5      | Estacionalidad y estadísticas descriptivas . . . . .                  | 9         |
| <b>3</b> | <b>Construcción de las series y partición (puntos 2 y 3)</b>          | <b>11</b> |
| 3.1      | Criterio de selección de las categorías . . . . .                     | 11        |
| 3.2      | Las siete series . . . . .                                            | 11        |
| 3.3      | Partición 70 / 30 . . . . .                                           | 13        |
| <b>4</b> | <b>Análisis de las series (punto 4)</b>                               | <b>13</b> |
| 4.1      | Descomposición, tendencia y estacionalidad . . . . .                  | 13        |
| 4.2      | Estacionariedad en varianza y transformación . . . . .                | 14        |
| 4.3      | Estacionariedad en media: autocorrelación y Dickey-Fuller . . . . .   | 15        |
| 4.4      | Selección de $p$ , $d$ y $q$ . . . . .                                | 17        |
| <b>5</b> | <b>Modelos, predicción y comparación (puntos 4.g a 4.k)</b>           | <b>18</b> |
| 5.1      | Resultado global sobre la partición 70/30 . . . . .                   | 18        |
| 5.2      | Control: partición alternativa post-pandemia . . . . .                | 19        |
| 5.3      | Análisis de residuos . . . . .                                        | 20        |
| 5.4      | Comparación detallada por serie . . . . .                             | 22        |
| <b>6</b> | <b>Análisis comparativo (punto 5)</b>                                 | <b>22</b> |
| 6.1      | Criterios de medición . . . . .                                       | 22        |

|          |                                                    |           |
|----------|----------------------------------------------------|-----------|
| 6.2      | Respuestas por categoría . . . . .                 | 24        |
| <b>7</b> | <b>Hallazgos útiles para el INGUAT (punto 5.b)</b> | <b>25</b> |
| 7.1      | Limitaciones del estudio . . . . .                 | 27        |

# 1 Introducción y datos

Este informe analiza el ingreso mensual de viajeros internacionales a Guatemala entre **enero de 2009 y junio de 2026**. La base contiene **161,036 registros** en formato largo: cada fila es una combinación de mes, vía de entrada, frontera, país de residencia y tipo de viajero, y la medida es la cantidad de viajeros. Al no existir filas de total, agregar por suma es seguro y no produce doble conteo.


El trabajo cubre los cinco puntos del enunciado: análisis exploratorio, partición de los datos, construcción de las series mensuales, análisis y modelado individual de cada serie, y comparación entre ellas. Todo el código está en los cuadernos de Python que acompañan a este documento; aquí se presentan únicamente resultados e interpretaciones.

## 1.1 Dos quiebres metodológicos que condicionan todo el análisis

Antes de construir cualquier serie fue necesario resolver dos discontinuidades en la forma en que se midieron los datos. Ninguna de las dos es un error de registro, pero ambas invalidan la comparación directa a lo largo del período completo.

**Primer quiebre (documentado en el enunciado).** Entre 2022 y 2023 la categoría *Tipo de Viajero* deja de contar a los viajeros no turísticos de alta frecuencia (comercio fronterizo, tránsito). La categoría Viajero cae de ~1.06 M en 2022 a ~0.33 M en 2023, un -69% sin ninguna causa económica. Además, Cruceristas desaparece por completo de la fuente desde 2023.

**Segundo quiebre (no documentado; aparece solo al mirar los datos).** Guatemala figura como país de residencia hasta 2022 y desaparece desde 2023. No es un mercado emisor extranjero: son guatemaltecos residentes que retornan, y aportaban cerca de **1.4 millones de personas al año**, alrededor de un tercio del total. Su salida explica buena parte de la caída aparente de 2023 y el escalón de la vía aérea (La Aurora pasa de 1.39 M a 0.99 M).



**Figura 1:** Viajeros por año y tipo (izquierda) y comparación entre el total crudo y Turista + Excursionista (derecha). La línea punteada marca el quiebre metodológico de 2023. El total agregado aparenta caer un 25% entre 2022 y 2023, cuando Turista + Excursionista solo se mueve de 3.23 M a 2.92 M.

**Decisión metodológica.** La **serie obligatoria** se construye como **Turista + Excursionista**, las dos únicas categorías consistentes en los 210 meses. Modelar el total crudo produciría un modelo que confunde un cambio de definición administrativa con una caída de demanda turística, y todo pronóstico heredaría ese sesgo.

## 2 Análisis exploratorio (punto 1)

### 2.1 Calidad de los datos: faltantes, duplicados y atípicos

**Valores faltantes.** No existe ningún valor nulo ni cadena vacía en las 13 columnas. Sin embargo, la ausencia de NaN no implica ausencia de faltantes: hay faltantes *codificados como texto* ('0', '0x2a') en las variables geográficas, un patrón típico de exportación de sistema. Afectan al **0.05% del volumen**, por lo que no alteran ninguna conclusión.

**Duplicados.** No hay duplicados exactos. Las 22 filas que se repiten según la llave lógica (año, mes, vía, frontera, país, tipo) **no son duplicados reales**: difieren en *Agrupación Residencia*, una columna etiquetada de forma inconsistente en el tramo 2020–2022 (España aparece a la vez como *España*, *Otros Europa* y *Resto de mundo*). Eliminarlas restaría viajeros que sí existen. **No se eliminan**: como todas las series se construyen agregando por suma, esas filas se consolidan solas y el total se conserva exacto. Sí se descarta *Agrupación Residencia* como variable de análisis por poco confiable.


**Valores atípicos.** Un atípico en una serie de tiempo no es un valor extremo del histograma, sino uno que se aparta de lo que la propia serie predice dadas su tendencia y su estacionalidad. Por eso se compararon dos criterios, y la diferencia entre ambos es instructiva:

- El **rango intercuartílico sobre el valor crudo** detecta **un solo punto** (diciembre 2019, el má-

ximo histórico) y **no detecta ningún mes de la pandemia**. La serie tiene tendencia y estacionalidad tan fuertes que su rango intercuartílico es enorme: los ~10 mil viajeros de abril 2020 caen dentro de ese rango amplísimo aunque sean absurdos para un mes de abril.


- El criterio basado en **residuos de una descomposición STL** —que descuenta primero tendencia y estacionalidad— identifica correctamente **siete meses consecutivos, de abril a octubre de 2020**, con abril 2020 a 7 desviaciones estándar de lo esperado.

**Conclusión práctica:** estos atípicos **no son errores y no deben eliminarse ni imputarse**. Son un choque exógeno real y agrupado en el tiempo. Eliminarlos sería borrar el evento más informativo de la serie.



**Figura 2:** Valores atípicos según los dos criterios. El IQR sobre el valor crudo (círculos verdes) no detecta la pandemia; el residuo STL (puntos rojos) sí.

## 2.2 Comportamiento temporal




**Figura 3:** Ingreso mensual de viajeros, enero 2009 – junio 2026.

A primera vista la serie muestra cuatro rasgos:

1. **Tendencia creciente y sostenida 2009–2019**, de ~1.88 M a ~4.13 M de visitantes anuales (+120% en once años, **8.19% anual compuesto**).
2. **Estacionalidad marcada y estable**, con picos que se repiten cada 12 meses.
3. **Un choque abrupto en marzo–abril 2020**: no es un atípico aislado sino un cambio de nivel que dura unos 15 meses.
4. **Recuperación en forma de escalón** desde mediados de 2021, que se estabiliza en un nivel **inferior** al de 2019.

Además, la amplitud de las oscilaciones **crece con el nivel** de la serie: primer indicio de varianza no constante, que se formaliza en la sección 4.2.

## 2.3 Impacto y recuperación de la pandemia





**engañoso**, y conviene desactivarla de inmediato porque es el error de lectura más fácil de cometer con estos datos.

El 2019 de esa comparación **sí** contabiliza a los residentes de Guatemala que retornan; el 2025 **no**, porque la metodología dejó de contarlos en 2023. Se está comparando una definición ancha contra una estrecha. En 2019 esos residentes eran **1,703,434 personas, el 41% del total**. Si se los excluye también de 2019, de modo que ambos años queden bajo la misma definición, el resultado se invierte:

| Base de comparación                                   | 2019      | 2025      | 2025 / 2019   |
|-------------------------------------------------------|-----------|-----------|---------------|
| Cruda (definiciones distintas)                        | 4,128,896 | 3,351,497 | 81.2%         |
| Homogénea (sin residentes de Guatemala en ambos años) | 2,425,462 | 3,351,497 | <b>138.2%</b> |


**Cuadro 1:** La “caída del 19%” del turismo es un artefacto del cambio de definición. A definición constante, 2025 supera a 2019 en un 38%.

**El turismo extranjero sí se recuperó y superó el nivel prepandemia:** +38% sobre 2019, equivalente a un 5.5% anual compuesto en seis años, coherente con el 8.19% de la etapa 2009–2019 descontando los dos años perdidos. Lo que no se recuperó —porque dejó de medirse— es el flujo de guatemaltecos retornantes.

Esto no invalida el modelado, pero sí precisa su interpretación: la serie que se modela **sí tiene un cambio de nivel permanente** y el modelo debe absorberlo, solo que su causa es **administrativa y no de demanda**. Un modelo que extrapole la tendencia 2009–2019 sobrestimará la serie, pero no porque el turismo se haya estancado, sino porque a partir de 2023 la serie mide una población más pequeña.


## 2.4 Países, regiones, vías y fronteras

Todos los rankings se calculan sobre el **total acumulado del período completo**, como pide el enunciado.




**Figura 5:** Top 10 países de residencia, acumulado 2009–2026.

**Países.** El Salvador (14.1 M, 30.1%), Guatemala (13.9 M, 29.7%) y Estados Unidos (7.0 M, 14.9%) concentran el **74.7%** del flujo; más de 200 países aportan el 25% restante. El perfil del crecimiento es **regional y terrestre**, no de larga distancia: El Salvador y Honduras ganan peso mientras la cuota de Estados Unidos se contrae.




**Figura 6:** Viajeros acumulados por región y evolución mensual de las tres principales.

**Regiones.** América Central (33.3 M, 71.3%), América del Norte (9.2 M, 19.6%) y Europa (2.1 M, 4.6%) explican el **95.5%** del flujo. Los tres perfiles son muy distintos —vía predominante, amplitud estacional y velocidad de recuperación— y por eso conviene modelarlos por separado en lugar de confiar solo en el agregado.



**Figura 7:** Ingreso mensual por vía y composición porcentual por año.

**Vías.** Medido sobre visitantes, la vía **terrestre domina con 59.1%**, seguida de la **aérea (40.7%)** y una **marítima residual (0.2%)**. La composición no es estática: la terrestre gana peso hasta 2019, salvo en 2021, cuando la aérea la supera (703 mil frente a 395 mil) porque los cierres fronterizos terrestres duraron más que la reapertura del aeropuerto. Buen ejemplo de que la pandemia **no afectó a todas las series por igual**.




**Figura 8:** Top 10 fronteras de ingreso, acumulado 2009–2026.


**Fronteras.** El flujo está muy concentrado: La Aurora (19.0 M, 40.7%), Valle Nuevo (10.1 M, 21.7%) y San Cristóbal (4.2 M, 9.0%) absorben el **71.3%**; las seis primeras llegan al 88.7%. El cruce frontera × vía confirma la lectura estructural: La Aurora es el flujo aéreo (100% de su volumen), y las cinco siguientes son terrestres, todas sobre la línea con El Salvador y Honduras.

## 2.5 Estacionalidad y estadísticas descriptivas

El patrón intra-anual se analiza sobre el período **pre-pandemia (2009–2019)** para que el colapso de 2020–2021 no distorsione el perfil.



**Figura 9:** Índice estacional (promedio del año = 100) y dispersión mensual, 2009–2019.



**Figura 10:** Viajeros por año y mes. El bloque claro de 2020–2021 es la pandemia.

El patrón es nítido y **muy estable año con año**:

- **Diciembre es el máximo absoluto (índice 134):** fiestas de fin de año y visita de la diáspora.
- **Marzo–abril (108 / 106):** Semana Santa. Al ser una **fiesta móvil**, en algunos años el pico cae en marzo y en otros en abril, lo que introduce ruido que un modelo estacional de período fijo (12) no captura del todo.
- **Julio–agosto (107 / 104):** vacaciones de mitad de año.
- **Los mínimos son febrero (81) y septiembre (83),** ambos ~20% por debajo del promedio.

La amplitud entre el mejor y el peor mes es de **52.6 puntos**: la componente estacional es económicamente relevante, no un detalle estadístico. El mapa de calor muestra además que el patrón **sobrevive intacto a la pandemia; el nivel no**.

### 3 Construcción de las series y partición (puntos 2 y 3)

#### 3.1 Criterio de selección de las categorías

El enunciado pide elegir **dos** categorías de análisis. El criterio aplicado fue el único defendible a la luz del exploratorio: **sirve la categoría cuyas series existan y sean comparables en los 210 meses.**

| Categoría                      | ¿Utilizable? | Razón                                                                                         |
|--------------------------------|--------------|-----------------------------------------------------------------------------------------------|
| Fronteras                      | Sí           | Definidas físicamente; las tres principales tienen serie completa.                            |
| Regiones ( <i>Región dos</i> ) | Sí           | Completas; absorben el quiebre de 2023 de forma explicable.                                   |
| Países de residencia           | Con reservas | Cambio de granularidad en 2023; Guatemala termina en 2022.                                    |
| Vías de ingreso                | No           | Marítima en cero desde 2017 y cruceros fuera de la base desde 2023: dos quiebres encadenados. |
| Tipo de viajero                | No           | Cruceristas desaparece en 2023 y Viajero sufre el quiebre de definición.                      |

**Cuadro 2:** Evaluación de las cinco categorías propuestas por el enunciado.

**Selección:** **Fronteras** (Top 3 acumulado) y **Regiones geográficas** (Top 3 de *Región dos*). Además de ser las más limpias, son las dos más útiles para el INGUAT: una responde a *por dónde entra* la gente (capacidad operativa) y la otra a *de dónde viene* (promoción de mercados).

#### 3.2 Las siete series

| Serie                           | Inicio  | Fin     | Frec.   | n   | Meses en 0 |
|---------------------------------|---------|---------|---------|-----|------------|
| Total (Turista + Excursionista) | 2009-01 | 2026-06 | Mensual | 210 | 0          |
| Frontera: La Aurora             | 2009-01 | 2026-06 | Mensual | 210 | 0          |
| Frontera: Valle Nuevo           | 2009-01 | 2026-06 | Mensual | 210 | 0          |
| Frontera: San Cristóbal         | 2009-01 | 2026-06 | Mensual | 210 | 0          |
| Región: América Del Centro      | 2009-01 | 2026-06 | Mensual | 210 | 0          |
| Región: América Del Norte       | 2009-01 | 2026-06 | Mensual | 210 | 5          |
| Región: Europa                  | 2009-01 | 2026-06 | Mensual | 210 | 5          |

**Cuadro 3:** Inciso 4.a: inicio, fin y frecuencia de cada serie. Las tres fronteras del Top 3 son La Aurora, Valle Nuevo y San Cristóbal; las tres regiones son América del Centro, América del Norte y Europa, todas por total acumulado del período completo. Los 5 meses en cero de América del Norte y Europa son abril–agosto de 2020: ceros reales por cierre de fronteras, no datos faltantes.

| Serie                           | Media   | Desv. est. | CV % | Mín   | Máx     |
|---------------------------------|---------|------------|------|-------|---------|
| Total (Turista + Excursionista) | 222,341 | 84,673     | 38.1 | 9,779 | 448,790 |
| Frontera: La Aurora             | 90,418  | 27,774     | 30.7 | 484   | 158,073 |
| Frontera: Valle Nuevo           | 48,292  | 23,448     | 48.6 | 80    | 111,127 |
| Frontera: San Cristóbal         | 19,916  | 11,392     | 57.2 | 14    | 53,120  |
| Región: América Del Centro      | 158,467 | 66,473     | 41.9 | 9,779 | 359,152 |
| Región: América Del Norte       | 43,605  | 17,880     | 41.0 | 0     | 98,361  |
| Región: Europa                  | 10,210  | 4,391      | 43.0 | 0     | 22,799  |

**Cuadro 4:** Estadísticas descriptivas de las siete series (viajeros por mes).



**Figura 11:** Las siete series y la partición cronológica 70/30.

### 3.3 Partición 70 / 30

El corte es **cronológico**, nunca aleatorio: usar datos del futuro para predecir el pasado es fuga de información y produce métricas de error optimistas y falsas.

| Conjunto            | Desde   | Hasta   | Meses |
|---------------------|---------|---------|-------|
| Entrenamiento (70%) | 2009-01 | 2021-03 | 147   |
| Prueba (30%)        | 2021-04 | 2026-06 | 63    |

**Cuadro 5:** Partición cronológica de las 210 observaciones.

**Advertencia central del informe.** El corte al 70% cae en **abril de 2021**, es decir, **dentro del hueco pandémico**. El conjunto de entrenamiento termina en el piso del colapso y el de prueba contiene toda la recuperación.

Es una partición **dura pero honesta**: ningún modelo entrenado hasta esa fecha puede anticipar la reapertura de fronteras, porque esa información sencillamente no está en los datos de entrenamiento. Los errores del conjunto de prueba serán altos **por construcción**, y un MAE o RMSE elevado **no** implica que el modelo esté mal especificado. Se respeta el 70/30 que pide el enunciado y en la sección 5.2 se reporta una partición alternativa post-pandemia que separa el error atribuible al choque exógeno del error propio del modelo.

## 4 Análisis de las series (punto 4)

Todas las series recibieron idéntico tratamiento, de modo que los resultados sean comparables entre sí. Esta sección resume los hallazgos transversales y luego detalla cada serie.

### 4.1 Descomposición, tendencia y estacionalidad

Se descompuso cada serie con **STL** sobre  $\log(1 + x)$  y se midió la fuerza de cada componente con los índices de Wang, Smith y Hyndman:

$$F_T = \max\left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(T_t + R_t)}\right), \quad F_S = \max\left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(S_t + R_t)}\right).$$

**Una precisión metodológica importante.** Calculados sobre la muestra completa, estos índices resultan engañosamente bajos: para la serie total dan  $F_T = 0.35$  y  $F_S = 0.05$ , cifras que sugerirían una serie casi sin tendencia ni estacionalidad, en contradicción directa con lo que muestra el gráfico. La causa es que **el residuo de la pandemia domina la varianza total** y hunde ambos cocientes.

Medidos sobre la ventana limpia **2009–2019**, los mismos índices dan  $F_T = 0.94$  y  $F_S = 0.80$ , que sí describen la serie. Por eso **todas las medidas de caracterización de este informe se calculan sobre 2009–2019**, y el impacto de la pandemia se mide aparte con estadísticos propios.

| Serie                           | 2009–2019 (limpio) |       | 2009–2026 (con pandemia) |       |
|---------------------------------|--------------------|-------|--------------------------|-------|
|                                 | $F_T$              | $F_S$ | $F_T$                    | $F_S$ |
| Total (Turista + Excursionista) | 0.941              | 0.795 | 0.348                    | 0.047 |
| Frontera: La Aurora             | 0.926              | 0.874 | 0.145                    | 0.049 |
| Frontera: Valle Nuevo           | 0.672              | 0.421 | 0.485                    | 0.059 |
| Frontera: San Cristóbal         | 0.833              | 0.706 | 0.650                    | 0.129 |
| Región: América Del Centro      | 0.950              | 0.805 | 0.550                    | 0.077 |
| Región: América Del Norte       | 0.701              | 0.882 | 0.119                    | 0.009 |
| Región: Europa                  | 0.600              | 0.880 | 0.281                    | 0.076 |

**Cuadro 6:** Fuerza de tendencia y estacionalidad. La caída al incluir 2020–2021 no significa que las series pierdan tendencia o estacionalidad: es un artefacto de la varianza del choque.

**Lectura.** Las siete series tienen **tendencia fuerte** ( $F_T \geq 0.60$ ) y **estacionalidad relevante** ( $F_S \geq 0.42$ ). Que una serie tenga estacionalidad significa que el mes del año es un predictor por sí mismo, y por tanto que un modelo sin términos estacionales está condenado a errar de forma sistemática y repetitiva. Que tenga tendencia significa que la media no es constante, y por tanto que la serie no puede ser estacionaria en media sin diferenciar.

## 4.2 Estacionariedad en varianza y transformación

Se evaluó con tres diagnósticos complementarios sobre 2009–2019: la correlación entre la media móvil y la desviación estándar móvil de 12 meses, la pendiente de  $\log(\text{sd})$  contra  $\log(\text{media})$  (0 indica varianza constante, 1 que la dispersión es proporcional al nivel) y el  $\lambda$  de Box-Cox.


| Serie                           | corr(media, sd) | pendiente | $\lambda$ | ¿Transformar? |
|---------------------------------|-----------------|-----------|-----------|---------------|
| Total (Turista + Excursionista) | 0.845           | 0.871     | −0.339    | Sí            |
| Frontera: La Aurora             | 0.873           | 0.824     | −0.515    | Sí            |
| Frontera: Valle Nuevo           | 0.174           | 0.194     | 0.703     | No            |
| Frontera: San Cristóbal         | 0.626           | 0.687     | 0.063     | Sí            |
| Región: América Del Centro      | 0.810           | 0.822     | −0.225    | Sí            |
| Región: América Del Norte       | 0.762           | 0.685     | 0.181     | Sí            |
| Región: Europa                  | 0.862           | 1.164     | 0.733     | Sí            |

**Cuadro 7:** Diagnóstico de estacionariedad en varianza (2009–2019).



**Conclusión.** En seis de las siete series la dispersión crece casi proporcionalmente al nivel (pendientes de 0.69 a 1.16) y el  $\lambda$  de Box-Cox se sitúa cerca de 0, que es exactamente el caso logarítmico. **Estas series no son estacionarias en varianza y requieren transformación.** La única excepción es Valle Nuevo, cuya dispersión es prácticamente independiente del nivel.


**Se modelaron todas en  $\log(1 + x)$ ,** incluida Valle Nuevo, por tres razones: estabiliza la varianza donde hace falta, garantiza que las predicciones devueltas a la escala original sean no negativas, y mantiene todas las series en una escala común para que la comparación sea legítima. El +1 evita el  $\log(0)$  de los meses de cierre total de fronteras de 2020.



**Figura 12:** Serie total: en escala original la desviación móvil sigue al nivel (izquierda); en escala logarítmica se aplanan (derecha).

### 4.3 Estacionariedad en media: autocorrelación y Dickey-Fuller

**Evidencia gráfica.** La función de autocorrelación de las series sin diferenciar **decae muy lentamente** y se mantiene positiva y significativa durante decenas de rezagos. Ese decaimiento lento es la firma gráfica de la **no estacionariedad en media**: si la serie fuera estacionaria, la ACF caería rápidamente hacia cero tras unos pocos rezagos. Se observa además un repunte en los rezagos múltiplos de 12, que corresponde a la componente estacional anual.



**Figura 13:** Serie total: ACF y PACF antes (arriba) y después (abajo) de diferenciar. Arriba, el decaimiento lento de la ACF evidencia la no estacionariedad en media; abajo, tras una diferencia regular, la ACF cae abruptamente.

**Evidencia estadística.** Se aplicaron dos pruebas con hipótesis nulas opuestas, que es la forma correcta de decidir: la **Dickey-Fuller aumentada** (ADF,  $H_0$ : hay raíz unitaria, es decir NO estacionaria) y la **KPSS** ( $H_0$ : Sí estacionaria).

| Serie                           | ADF original | ADF log | ADF log + 1 dif. | $d$ |
|---------------------------------|--------------|---------|------------------|-----|
| Total (Turista + Excursionista) | 0.0470       | 0.0833  | 0.0001           | 1   |
| Frontera: La Aurora             | 0.0185       | 0.0077  | 0.0000           | 0   |
| Frontera: Valle Nuevo           | 0.0344       | 0.0185  | 0.0000           | 0   |
| Frontera: San Cristóbal         | 0.2330       | 0.0235  | 0.0000           | 0   |
| Región: América Del Centro      | 0.0448       | 0.0544  | 0.0002           | 1   |
| Región: América Del Norte       | 0.2196       | 0.0393  | 0.0000           | 0   |
| Región: Europa                  | 0.0222       | 0.0231  | 0.0000           | 0   |

**Cuadro 8:** Valores  $p$  de la prueba de Dickey-Fuller aumentada y número de diferencias regulares resultante. Un  $p < 0.05$  permite rechazar la raíz unitaria.

**Qué hay que hacer para volverlas estacionarias en media. Diferenciar.** En las dos series agregadas (Total y América del Centro) la ADF no permite rechazar la raíz unitaria en la escala logarítmica ( $p = 0.083$  y  $p = 0.054$ ), y una sola diferencia regular basta para que el  $p$  caiga a 0.0001 o menos:  $d = 1$ . En las cinco restantes la ADF ya rechaza la raíz unitaria en la serie transformada, de modo que  $d = 0$  y la estacionariedad en media se consigue solo con la transformación logarítmica.

Este resultado merece una advertencia: la forma en V de la pandemia —caída brusca seguida de recuperación— hace que la serie *parezca* revertir a la media y vuelve el resultado de la ADF sensible a esa ventana. Por eso se contrastó con la **KPSS**, que no rechaza la estacionariedad en ningún caso tras la transformación, y por eso se incluyeron de todos modos modelos con diferenciación entre los candidatos: la decisión final se tomó comparando el ajuste real, no un único valor  $p$ .

**Diferenciación estacional.** Se aplicó la prueba **OCSB** de raíz unitaria estacional. Devuelve  $D = 0$  para cinco series y  $D = 1$  para América del Norte y Europa. Que la OCSB devuelva 0 no contradice la fuerte estacionalidad detectada: la prueba busca una raíz unitaria *estacional* (una estacionalidad que cambia de forma aleatoria año con año), y la de estas series es **determinista y muy estable**, por lo que se captura mejor con términos estacionales AR/MA que diferenciando. Aun así, se incluyó siempre el modelo “aerolínea”  $(0, 1, 1)(0, 1, 1)_{12}$  con diferenciación estacional forzada, para que fuera la comparación empírica y no un supuesto previo la que decidiera.

#### 4.4 Selección de $p$ , $d$ y $q$

Los órdenes se eligieron combinando dos fuentes. **Primero, la lectura de la ACF y la PACF** sobre la serie ya estacionarizada: una PACF que se corta en el rezago  $k$  y una ACF que decae sugieren un  $AR(k)$ ; el patrón inverso sugiere un MA; los picos en los rezagos 12 y 24 indican las componentes estacionales. **Segundo, auto\_arima**, forzándole los valores de  $d$  y  $D$  obtenidos de las pruebas formales y dejándole optimizar  $p$ ,  $q$ ,  $P$  y  $Q$  por AIC.

| Serie                           | $d$ | $D$ | Propuesta de auto_arima                |
|---------------------------------|-----|-----|----------------------------------------|
| Total (Turista + Excursionista) | 1   | 0   | SARIMA(0, 1, 0)(2, 0, 0) <sub>12</sub> |
| Frontera: La Aurora             | 0   | 0   | SARIMA(1, 0, 1)(1, 0, 1) <sub>12</sub> |
| Frontera: Valle Nuevo           | 0   | 0   | SARIMA(1, 0, 1)(0, 0, 0) <sub>12</sub> |
| Frontera: San Cristóbal         | 0   | 0   | SARIMA(3, 0, 0)(2, 0, 0) <sub>12</sub> |
| Región: América Del Centro      | 1   | 0   | SARIMA(0, 1, 0)(2, 0, 0) <sub>12</sub> |
| Región: América Del Norte       | 0   | 1   | SARIMA(3, 0, 2)(0, 1, 0) <sub>12</sub> |
| Región: Europa                  | 0   | 1   | SARIMA(2, 0, 2)(0, 1, 0) <sub>12</sub> |

**Cuadro 9:** Órdenes de diferenciación determinados por ADF y OCSB, y modelo propuesto por auto\_arima.

**¿Tienen sentido los modelos propuestos?** En general sí, y son interpretables:

- Para el **Total** y **América del Centro**, auto\_arima propone  $(0, 1, 0)(2, 0, 0)_{12}$ : un paseo aleatorio con deriva más dos términos autorregresivos estacionales. Es coherente con lo observado: el nivel del mes que viene se explica sobre todo por el de este mes (de ahí  $p = q = 0$  tras diferenciar), y lo que queda por explicar es el patrón anual, capturado por los rezagos 12 y 24.

- Para **La Aurora**,  $(1, 0, 1)(1, 0, 1)_{12}$  combina memoria de corto plazo con memoria estacional, razonable para un aeropuerto con reservas anticipadas y temporadas bien definidas.
- Para **San Cristóbal**,  $(3, 0, 0)(2, 0, 0)_{12}$  es un AR puro relativamente largo, consistente con una serie de frontera terrestre con inercia mensual alta.
- Para **América del Norte y Europa**, la diferenciación estacional ( $D = 1$ ) domina la especificación, coherente con series cuyo comportamiento está regido casi enteramente por la temporada.

**Advertencia sobre la comparación de AIC y BIC.** Estos criterios **solo son comparables entre modelos ajustados sobre el mismo número efectivo de observaciones**. Diferenciar consume datos: un modelo con  $d = 1, D = 1$  evalúa su verosimilitud sobre 134 observaciones y uno con  $d = 1, D = 0$  sobre 146. Comparar sus AIC directamente es un error frecuente. Por eso, en las tablas siguientes se reporta la columna  $n_{ef}$  y el mejor modelo por AIC se selecciona **solo dentro del grupo que comparte ese valor**. MAE, RMSE y MAPE, en cambio, se calculan siempre sobre el mismo conjunto de prueba y en la escala original, por lo que sí son comparables entre todos los modelos.

## 5 Modelos, predicción y comparación (puntos 4.g a 4.k)

Para cada serie se ajustaron **seis modelos SARIMA** (el de `auto_arima`, tres variantes derivadas de la ACF/PACF y dos modelos con diferenciación estacional forzada) más los **cuatro algoritmos alternativos** que pide el enunciado: **Prophet**, **Holt-Winters**, **suavizamiento exponencial simple** y **seasonal naive**. En total, diez modelos por serie y setenta en el estudio.


### 5.1 Resultado global sobre la partición 70/30

| Serie                           | Mejor modelo (RMSE)      | MAPE % | RMSE    |
|---------------------------------|--------------------------|--------|---------|
| Total (Turista + Excursionista) | Suav. exponencial simple | 60.6   | 173,699 |
| Frontera: La Aurora             | Suav. exponencial simple | 36.6   | 42,064  |
| Frontera: Valle Nuevo           | Suav. exponencial simple | 80.3   | 46,248  |
| Frontera: San Cristóbal         | Suav. exponencial simple | 81.5   | 23,721  |
| Región: América Del Centro      | Suav. exponencial simple | 61.4   | 120,333 |
| Región: América Del Norte       | Suav. exponencial simple | 53.4   | 36,714  |
| Región: Europa                  | Suav. exponencial simple | 71.4   | 10,689  |

**Cuadro 10:** Mejor modelo por RMSE sobre el conjunto de prueba 2021-04 a 2026-06.

**Este resultado hay que leerlo con cuidado, porque es un artefacto de la partición.** El suavizamiento exponencial simple —el modelo **más pobre** de los diez, incapaz de representar tendencia o estacionalidad— gana en las siete series. La razón es puramente estructural: al entrenar hasta marzo de 2021, todos los modelos “ven” una serie que termina en el piso del colapso. Los modelos con tendencia y estacionalidad proyectan hacia adelante la trayectoria deprimida y estacional del período pandémico; el suavizamiento simple proyecta una línea plana en el último nivel, y esa línea plana resulta estar accidentalmente más cerca de la recuperación que ninguna extrapolación informada.

Dicho de otro modo: **con esta partición no se está midiendo qué modelo captura mejor la dinámica de la serie, sino cuál se equivoca menos ante un cambio estructural que ninguno podía prever.** Los MAPE de 36% a 82% no son una medida de la calidad de los modelos.



## 5.2 Control: partición alternativa post-pandemia

Para separar el error del choque exógeno del error propio del modelo, se repitió todo el ejercicio entrenando desde **julio de 2021** (fronteras ya reabiertas) y dejando los **últimos 18 meses** como prueba.

| Serie                      | Partición 70/30   |        | Control post-pandemia                  |             |
|----------------------------|-------------------|--------|----------------------------------------|-------------|
|                            | Mejor modelo      | MAPE % | Mejor modelo                           | MAPE %      |
| Total (Tur.+Exc.)          | Suav. exp. simple | 60.6   | Seasonal naive                         | <b>6.0</b>  |
| Frontera: La Aurora        | Suav. exp. simple | 36.6   | SARIMA(1, 0, 0)(1, 0, 0) <sub>12</sub> | <b>8.3</b>  |
| Frontera: Valle Nuevo      | Suav. exp. simple | 80.3   | Seasonal naive                         | <b>12.7</b> |
| Frontera: San Cristóbal    | Suav. exp. simple | 81.5   | Seasonal naive                         | <b>14.3</b> |
| Región: América Del Centro | Suav. exp. simple | 61.4   | Seasonal naive                         | <b>9.8</b>  |
| Región: América Del Norte  | Suav. exp. simple | 53.4   | Prophet                                | <b>7.2</b>  |
| Región: Europa             | Suav. exp. simple | 71.4   | SARIMA(1, 0, 1)(1, 0, 1) <sub>12</sub> | <b>12.5</b> |

**Cuadro 11:** Comparación de las dos particiones. El error cae de 36–82% a 6–14% al eliminar el quiebre estructural del conjunto de entrenamiento.

**Este es el hallazgo metodológico central del laboratorio.** El MAPE cae de un rango de **36–82%** a un rango de **6–14%**, una reducción de un orden de magnitud, sin cambiar ni un solo modelo ni un solo dato. La conclusión es inequívoca: **el error de la partición 70/30 no mide la calidad de los modelos, mide la magnitud del choque pandémico**. Sobre datos homogéneos, estas series son **muy predecibles**: un error del 6–14% a un horizonte de 18 meses es un resultado sólido para planificación turística.

Nótese además que en el control cambian los ganadores y aparecen modelos con estructura estacional —seasonal naive, SARIMA con términos estacionales, Prophet—, exactamente lo esperable en series con  $F_S$  entre 0.42 y 0.88. El suavizamiento exponencial simple desaparece del podio, confirmando que su victoria anterior era un accidente de la partición.

### 5.3 Análisis de residuos

Se evaluaron los residuos del mejor SARIMA de cada serie con la prueba de **Ljung-Box** ( $H_0$ : los residuos son ruido blanco) y **Jarque-Bera** ( $H_0$ : son normales).


| Serie                           | Ljung-Box(12) | Ljung-Box(24) | ¿Ruido blanco? |
|---------------------------------|---------------|---------------|----------------|
| Total (Turista + Excursionista) | 0.274         | —             | Sí             |
| Frontera: La Aurora             | 0.025         | —             | Marginal       |
| Frontera: Valle Nuevo           | 0.048         | —             | Marginal       |
| Frontera: San Cristóbal         | 0.045         | —             | Marginal       |
| Región: América Del Centro      | 0.285         | —             | Sí             |
| Región: América Del Norte       | 0.000         | 0.000         | <b>No</b>      |
| Región: Europa                  | 0.000         | 0.000         | <b>No</b>      |

**Cuadro 12:** Valores  $p$  de Ljung-Box sobre los residuos del mejor SARIMA de cada serie.

**Interpretación honesta de estos resultados.** En las dos series agregadas los residuos son ruido blanco: el modelo ha extraído toda la estructura disponible. En las tres fronteras el resultado es marginal (valores  $p$  entre 0.025 y 0.048), lo que indica algo de autocorrelación residual, atribuible en buena medida a la **Semana Santa**: al ser una fiesta móvil que salta entre marzo y abril, un modelo estacional de período fijo 12 no puede capturarla y deja residuo sistemático en esos meses.

En **América del Norte y Europa el modelo es claramente inadecuado** ( $p = 0.000$ ). La causa es identificable: son las dos únicas series con **cinco meses en cero** (abril a agosto de 2020, cuando el ingreso de extranjeros fue literalmente nulo). En escala logarítmica ese cero es un salto de magnitud enorme respecto del nivel habitual, y ningún SARIMA lineal puede absorberlo. **El tratamiento correcto sería incorporar variables dummy de intervención** para la ventana de cierre (un modelo ARIMAX), o tratar esos meses como *no observados* en lugar de como ceros, dado que la frontera cerrada significa que la demanda no se midió, no que fuera cero. Se deja explícitamente señalado como la principal limitación del modelado de estas dos series.

En las siete series la prueba de **Jarque-Bera rechaza la normalidad** ( $p < 0.001$ ), lo que era esperable: los residuos de 2020 son valores extremos genuinos. Esto no invalida las predicciones puntuales, pero sí implica que **los intervalos de confianza calculados bajo el supuesto de normalidad son demasiado estrechos** y no deben tomarse al pie de la letra.



**Figura 15:** Serie total: diagnóstico de residuos del mejor SARIMA. La ACF de los residuos no muestra estructura remanente; el Q-Q evidencia las colas pesadas de la pandemia.

## 5.4 Comparación detallada por serie

A continuación se presenta la tabla completa de modelos para la serie obligatoria. Las tablas de las seis series restantes siguen el mismo formato y están en el cuaderno de análisis.

| Modelo                                        | AIC         | BIC         | $n_{ef}$ | MAE     | RMSE    | MAPE |
|-----------------------------------------------|-------------|-------------|----------|---------|---------|------|
| Suav. exponencial simple                      | -326.1      | -320.1      | 147      | 158,767 | 173,699 | 60.6 |
| SARIMA(0, 1, 1)(0, 0, 1) <sub>12</sub>        | 86.9        | 95.6        | 146      | 163,231 | 176,622 | 63.5 |
| Holt-Winters                                  | -354.3      | -306.4      | 147      | 178,380 | 192,809 | 68.6 |
| SARIMA(2, 1, 0)(1, 0, 0) <sub>12</sub>        | 79.8        | 91.4        | 146      | 197,207 | 209,470 | 79.6 |
| Seasonal naive                                | —           | —           | 147      | 207,293 | 219,634 | 84.9 |
| SARIMA(1, 1, 1)(1, 0, 1) <sub>12</sub>        | 70.9        | 85.3        | 146      | 208,232 | 223,054 | 82.0 |
| SARIMA(1, 1, 1)(0, 1, 1) <sub>12</sub>        | 70.6        | 81.7        | 134      | 213,023 | 227,948 | 84.1 |
| SARIMA(0, 1, 1)(0, 1, 1) <sub>12</sub>        | 68.9        | 77.2        | 134      | 213,851 | 228,724 | 84.5 |
| SARIMA(0, 1, 0)(2, 0, 0) <sub>12</sub> (auto) | <b>58.8</b> | <b>67.2</b> | 146      | 217,446 | 237,176 | 83.0 |
| Prophet                                       | —           | —           | 147      | 240,279 | 252,691 | 98.2 |

**Cuadro 13:** Serie total: comparación de los diez modelos, ordenados por RMSE sobre el conjunto de prueba. Recuerdese que AIC y BIC solo son comparables dentro del mismo  $n_{ef}$ .

**Lectura de la tabla, y por qué AIC y RMSE apuntan en direcciones opuestas.** Dentro del grupo  $n_{ef} = 146$ , el mejor modelo por **AIC y BIC** es SARIMA(0, 1, 0)(2, 0, 0)<sub>12</sub>, el que propone `auto_arima`, y sus residuos son ruido blanco ( $p = 0.274$ ). Sin embargo, ese mismo modelo queda **penúltimo por RMSE**. No hay contradicción: **el AIC mide el ajuste dentro de la muestra de entrenamiento y el RMSE mide el error fuera de ella**. El modelo describe muy bien el período 2009–2021 —incluida la pandemia— y precisamente por eso proyecta hacia adelante un nivel deprimido. El criterio correcto para **seleccionar un modelo de pronóstico es el error fuera de muestra**, pero en este caso ese error está dominado por el quiebre estructural, y por eso la decisión final se apoya en la partición de control de la sección 5.2.

## 6 Análisis comparativo (punto 5)

### 6.1 Criterios de medición


Cada pregunta se responde con un estadístico explícito, para que la comparación sea reproducible y no dependa de la lectura visual de los gráficos.



| Pregunta                       | Estadístico                                                       |
|--------------------------------|-------------------------------------------------------------------|
| Mayor estacionalidad           | Fuerza estacional $F_S$ de la descomposición STL (2009–2019)      |
| Mayor tendencia de crecimiento | Tasa de crecimiento anual compuesta (TCAC) 2009–2019              |
| Mayor volatilidad              | Desviación estándar de $\log(y_t/y_{t-12})$ (2009–2019)           |
| Más afectada por la pandemia   | Caída del total de 2020 respecto de 2019 y nivel de 2025 vs. 2019 |

| Serie                           | $F_S$        | TCAC %       | Volat.       | Caída 2020 % | 2025 vs 2019 % |              |
|---------------------------------|--------------|--------------|--------------|--------------|----------------|--------------|
|                                 |              |              |              |              | cruda          | homog.       |
| Total (Turista + Excursionista) | 0.795        | 8.19         | 0.105        | –74.4        | 81.2           | 138.2        |
| Frontera: La Aurora             | <b>0.874</b> | 4.74         | 0.074        | –72.8        | 80.3           | 147.8        |
| Frontera: Valle Nuevo           | 0.421        | 9.69         | <b>0.373</b> | <b>–80.7</b> | 71.7           | <b>106.6</b> |
| Frontera: San Cristóbal         | 0.706        | <b>12.95</b> | 0.304        | –72.6        | 90.2           | 159.1        |
| Región: América Del Centro      | 0.805        | <b>9.83</b>  | <b>0.122</b> | <b>–74.4</b> | 66.0           | 138.8        |
| Región: América Del Norte       | <b>0.882</b> | 3.82         | 0.106        | –74.1        | 139.3          | 139.3        |
| Región: Europa                  | 0.880        | 2.23         | 0.110        | –71.9        | 125.8          | <b>125.8</b> |

**Cuadro 14:** Comparación entre series. En negrita el máximo (o mínimo, según corresponda) dentro de cada categoría. La columna **cruda** compara un 2019 que incluye residentes de Guatemala contra un 2025 que no; la **homogénea** los excluye de ambos años y es la única interpretable. En América del Norte y Europa ambas coinciden porque esas regiones nunca contuvieron residentes guatemaltecos.



**Figura 16:** Comparación visual de los cuatro criterios. Azul: fronteras; verde: regiones; gris: total.

## 6.2 Respuestas por categoría

### Categoría 1 — Fronteras

- i. **Mayor estacionalidad: La Aurora** ( $F_S = 0.874$ ). El aeropuerto tiene el patrón anual más marcado y regular, coherente con un flujo dominado por vacaciones planificadas y visita de la diáspora en diciembre. Valle Nuevo, en cambio, es la menos estacional ( $F_S = 0.421$ ): el tránsito terrestre con El Salvador tiene un componente cotidiano y comercial que no depende de la temporada.
- ii. **Mayor tendencia de crecimiento: San Cristóbal** (TCAC = 12.95% anual 2009–2019). Casi triplica el ritmo de La Aurora (4.74%). Es el corredor con Honduras y el de mayor dinamismo estructural del período.
- iii. **Mayor volatilidad: Valle Nuevo** (sd de la tasa interanual = 0.373), cinco veces la de La Aurora (0.074). El flujo aéreo es el más estable y predecible; el terrestre con El Salvador, el más errático.
- iv. **Más afectada por la pandemia: Valle Nuevo**, con una caída del **80.7%** en 2020 frente a 2019 —la única que superó el 80%— y además la **peor recuperada**: a definición homogénea está en el **106.6%** de 2019, apenas por encima del nivel prepandemia, mientras La Aurora alcanza el 147.8% y San Cristóbal el 159.1%. El orden de las tres fronteras es el mismo con la comparación cruda (71.7%, 80.3% y 90.2%), de modo que **esta respuesta no depende del criterio**: cambia la magnitud, no el diagnóstico. Las tres tocaron un piso cercano al  $-100\%$  en el peor mes; lo que las distingue es la velocidad de recuperación.

### Categoría 2 — Regiones geográficas

- i. **Mayor estacionalidad: América del Norte** ( $F_S = 0.882$ ), seguida muy de cerca por Europa (0.880). Ambos son mercados de larga distancia con temporadas bien definidas (verano boreal e invierno). América Central es la menos estacional (0.805), por su componente de viaje regional frecuente.
- ii. **Mayor tendencia de crecimiento: América Central** (TCAC = 9.83%), muy por encima de América del Norte (3.82%) y Europa (2.23%). Confirma el hallazgo del exploratorio: **el crecimiento del turismo guatemalteco fue regional, no de larga distancia**.
- iii. **Mayor volatilidad: América Central** (0.122), aunque las tres regiones son notablemente parecidas (0.106–0.122). A nivel regional los flujos se promedian entre muchos puntos de entrada y la volatilidad se diluye; es a nivel de frontera individual donde aparecen las diferencias grandes.

- iv. **Más afectada en 2020: América Central**, con una caída del **74.4%**, seguida muy de cerca por América del Norte ( $-74.1\%$ ) y Europa ( $-71.9\%$ ). Las tres son prácticamente indistinguibles: el cierre de fronteras fue indiscriminado. **Peor recuperada: Europa**, con un **125.8%** del nivel de 2019, frente a 138.8% de América Central y 139.3% de América del Norte. Las tres superan su nivel prepandemia.

**Advertencia imprescindible: en esta categoría la respuesta cambia según el criterio.** Con la comparación **cruda**, América Central aparece como la peor recuperada con un 66.0%, y era la respuesta que arrojaba un primer análisis. **Es falsa.** América Central es precisamente la región donde estaban clasificados los residentes de Guatemala, que representaban el **52.5% de la región en 2019** y desaparecen del conteo desde 2023. Al comparar un 2019 que los incluye contra un 2025 que no, se mide el cambio de definición y no la demanda:

| América Central | Total            | Residentes de Guatemala | Sin Guatemala |
|-----------------|------------------|-------------------------|---------------|
| 2019            | 3,247,484        | 1,703,434 (52.5%)       | 1,544,050     |
| 2025            | 2,143,511        | 0 (0%)                  | 2,143,511     |
| 2025 / 2019     | 66.0% (engañoso) | —                       | <b>138.8%</b> |

**Cuadro 15:** El “desplome” de América Central es enteramente un artefacto de definición: a definición constante la región creció un 38.8% sobre 2019.

En cambio, las cifras de **América del Norte y Europa no requieren corrección**: ninguna de las dos contuvo nunca residentes guatemaltecos, y su composición interna se mantiene comparable — América del Norte conserva las mismas tres categorías (Estados Unidos, México, Canadá) en 2019 y en 2025, y en Europa la agregación de mercados de 2023 reagrupó países *dentro* de la misma región, sin trasvasar volumen a otras. Sus crecimientos del 39% y 26% sobre 2019 son **reales**.

La lección general es que **ninguna comparación con años anteriores a 2023 es válida sin homogeneizar antes la definición**, y que hacerlo puede invertir por completo la conclusión.

## 7 Hallazgos útiles para el INGUAT (punto 5.b)

1. **Las estadísticas oficiales tienen dos rupturas de serie que invalidan cualquier comparación directa 2022 vs. 2023.** El total agregado aparenta caer 25%, pero se debe a un cambio de definición y a la salida de los residentes guatemaltecos del conteo, no a una pérdida de demanda turística. **Recomendación operativa:** publicar la serie *Turista + Excursionista* como indicador oficial de continuidad y documentar el quiebre. Si no se hace, cualquier informe de gestión que compare esos años estará reportando una caída que no ocurrió.

2. **El turismo extranjero sí se recuperó, y con holgura: la “caída del 19%” no existe.** Es el hallazgo más importante del informe porque contradice la lectura directa de los datos. La cifra de que 2025 está en el 81% del nivel de 2019 compara un 2019 que incluye a 1.7 millones de residentes guatemaltecos retornantes contra un 2025 que ya no los cuenta. A definición homogénea, **2025 está en el 138% de 2019** (+38%, un 5.5% anual compuesto). **Recomendación:** el INGUAT no debe reportar caídas ni diseñar planes de reactivación sobre esa comparación. Lo que cayó es la cobertura del indicador, no la demanda. El único dato de desaceleración genuino —y homogéneo, porque compara dos años posteriores al quiebre— es que el primer semestre de 2026 va **3% por debajo** del mismo semestre de 2025; eso sí merece seguimiento.
3. **Tres puestos fronterizos concentran el 71% del flujo.** La Aurora (40.7%), Valle Nuevo (21.7%) y San Cristóbal (9.0%). Un plan de capacidad, señalización, migración o promoción concentrado en esos tres puntos cubre casi tres cuartas partes del movimiento del país con una fracción del presupuesto de una intervención nacional.
4. **El crecimiento es regional y terrestre, no de larga distancia.** América Central creció al 9.83% anual entre 2009 y 2019, frente al 3.82% de América del Norte y el 2.23% de Europa. **Implicación de política:** el presupuesto de promoción internacional debería reflejar esta asimetría. El mercado que sostiene el volumen es el vecino, y es además el más barato de captar.
5. **Valle Nuevo es el punto que exige atención prioritaria.** Es simultáneamente la frontera **más afectada** por la pandemia (−80.7% en 2020), la **peor recuperada** (106.6% del nivel de 2019 a definición homogénea, cuando las otras dos superan el 147%) y la **más volátil** (cinco veces La Aurora). Concentra el problema y la incertidumbre a la vez, y su diagnóstico es robusto: sale peor con cualquiera de los dos criterios de comparación.
6. **San Cristóbal es la oportunidad de crecimiento.** Mayor tendencia de todas (12.95% anual 2009–2019) y mejor recuperación (159.1% de 2019 a definición homogénea). Es el corredor con Honduras y el de mayor dinamismo estructural del país; conviene acompañar ese crecimiento con inversión en capacidad antes de que se sature.
7. **La estacionalidad sobrevivió intacta a la pandemia; el nivel no.** El patrón anual —máximo en diciembre (índice 134), mínimos en febrero (81) y septiembre (83), amplitud de 53 puntos— se mantiene idéntico después de 2021, solo que a menor escala. **Esto es una buena noticia operativa:** significa que la planificación de personal, turnos migratorios y capacidad hotelera por temporada sigue siendo válida con el calendario histórico; lo único que cambió es el volumen base.
8. **Estas series son altamente predecibles sobre datos homogéneos.** La partición de control demuestra un **MAPE de 6–14% a 18 meses vista**, un margen perfectamente utilizable para presupuestar y dimensionar operaciones. El error del 36–82% de la partición oficial mide el choque

pandémico, no la calidad de los modelos.

9. **Los modelos más simples con estructura estacional son suficientes.** En el control post-pandemia, el **seasonal naive** —predecir el mismo mes del año anterior— gana en cuatro de las siete series. **Implicación práctica:** el INGUAT no necesita infraestructura analítica sofisticada para obtener pronósticos útiles; necesita series limpias y sin rupturas de definición. El cuello de botella es la calidad del dato, no el algoritmo.
10. **Recomendación de medición.** Los meses de frontera cerrada deberían registrarse como *no medidos*, no como cero. Tal como están, distorsionan el modelado de América del Norte y Europa hasta el punto de que ningún SARIMA lineal logra residuos de ruido blanco. Es una corrección de bajo costo y alto impacto para el uso analítico futuro de la base.

## 7.1 Limitaciones del estudio

- La partición 70/30 que exige el enunciado corta **dentro del hueco pandémico**, lo que hace que las métricas de error de la sección 5.1 no sean informativas sobre la calidad de los modelos. Se mitigó con la partición de control, pero es una limitación de diseño.
- Los modelos de **América del Norte y Europa** dejan autocorrelación residual significativa por los cinco meses en cero de 2020. Requerirían un ARIMAX con variables de intervención, fuera del alcance de este laboratorio.
- La **Semana Santa** es una fiesta móvil entre marzo y abril y ningún modelo estacional de período fijo 12 la captura; explica parte del residuo de las series de frontera.
- Toda comparación que cruce el año **2023** exige homogeneizar la definición antes de interpretarla. En este informe se hizo excluyendo a los residentes de Guatemala de ambos extremos; es la corrección de primer orden y explica la práctica totalidad de la discrepancia, pero no captura efectos residuales de la reagrupación de mercados dentro de cada región.
- Los datos son **de uso académico** y no corresponden a cifras oficiales del INGUAT ni del Instituto Guatemalteco de Migración.

---

**Repositorio del código:** [https://github.com/rodrigoajmac/CC3084\\_Laboratorio\\_1](https://github.com/rodrigoajmac/CC3084_Laboratorio_1)

Los cuadernos `01_EDA_series_tiempo.ipynb`, `02_Analysis_TimeSeries.ipynb` y `03_Modelado_Prediccion.ipynb` contienen el análisis exploratorio, la exploración inicial de series alternativas y el modelado completo, respectivamente.