

Laboratorio 1. Series de Tiempo.

INSTRUCCIONES:

Se trabajará en este laboratorio con los datos históricos de ingreso de viajeros internacionales a Guatemala. Esta hoja de trabajo se realizará en Grupos de tres. Para que se pueda calificar su laboratorio debe estar inscrito en algún grupo de canvas.

DESCRIPCIÓN DEL DATASET

El conjunto de datos contiene información mensual sobre el ingreso de viajeros, incluyendo: Año, Mes, Vía de ingreso, Frontera, País de residencia, Región, Región OMT, Agrupación de residencia, Tipo de viajero y Cantidad de viajeros.

Las variables que tiene este conjunto de datos son las siguientes:

- **Año:** Año de ingreso al país
- **Mes cod:** Codificación del mes
- **Mes:** Nombre del mes
- **Vía:** Vía de entrada (Aérea, Terrestre, Marítima)
- **Frontera:** Frontera de ingreso
- **País:** Hasta el año 2023 país de procedencia después de 2023 agrupación de mercado
- **Región:** Clasificación utilizada para reportes nacionales.
- **Región dos:** Agrupa varias categorías de *Región* en continentes o grandes áreas
- **Regiones OMT:** Subregión de la Organización Mundial del Turismo
- **MCEO:** Mercado o agrupación comercial estratégica. Clasificación de mercados objetivo utilizada para análisis de turismo.
- **Agrupación Residencia:** Región donde reside
- **Tipo de Viajero:** Puede ser Turista, Crucerista, Excursionista, Viajero, Visitante
- **Viajero:** Cantidad de viajeros

Entre 2022 y 2023 el “**tipo de Viajero**” excluye a los viajeros no turísticos de alta frecuencia (comercio fronterizo, tránsito). Por eso la categoría "Viajero" disminuye fuertemente en 2023 y el total anual parece caer, pero no es caída real de turismo. Para comparar en todo el rango use Turista + Excursionista, que sí son consistentes durante todo el período.

Algunos vínculos interesantes:

- <https://otexts.com/fpp2/>
- <https://otexts.com/fpp2/arima.html>
- <https://otexts.com/fpp2/accuracy.html>
- <https://otexts.com/fpp3/holt-winters.html>
- <https://otexts.com/fpp3/expsmooth.html>

- <https://otexts.com/fpp3/simple-methods.html#seasonal-na%C3%AFve-method>

NOTA: Los datos proporcionados son solo para uso académico, no corresponden a datos oficiales ni del INGUAT ni del Instituto Guatemalteco de Migración.

EJERCICIOS

1. Realice un análisis exploratorio del conjunto de datos. Como mínimo incluya:
 - a. comportamiento temporal del número de viajeros;
 - b. países con mayor cantidad de viajeros;
 - c. regiones con mayor cantidad de viajeros;
 - d. vías de ingreso y fronteras más utilizadas;
 - e. análisis de valores faltantes, duplicados y valores atípicos;
 - f. estadísticas descriptivas y visualizaciones con su respectiva interpretación.
2. Divida el conjunto de datos en entrenamiento y prueba, aproximadamente 70% entrenamiento, 30% para prueba.
3. A partir del conjunto de datos de entrenamiento construya series de tiempo **mensuales**, agregando el número de viajeros según la categoría correspondiente. Si considera que necesita limpieza hágala.
 - a. **Serie obligatoria:** Total mensual de viajeros internacionales.
 - b. Además, debe seleccionar **dos** de las siguientes categorías de análisis. Para cada categoría seleccionada deberán construir **una serie por cada valor indicado**.
 - i. **Países de residencia**

Construya una serie mensual para cada uno de los **tres países con mayor número acumulado de viajeros** durante todo el período de estudio (Top 3). En total deberá obtener **tres series**.

- ii. **Regiones geográficas**

Construya una serie mensual para las 3 regiones que más viajeros aporta de la variable **Región dos**. En total deberá obtener una serie para cada región (3 series).

- iii. **Vías de ingreso**

Construya una serie mensual para cada vía de ingreso:

- Aérea
- Terrestre
- Marítima

En total deberá obtener **tres series**.

- iv. **Fronteras**

Identifique las **tres fronteras con mayor número acumulado de viajeros** durante todo el período de estudio y construya una serie mensual para cada una de ellas. En total deberá obtener **tres series**.

v. Tipo de viajero

Construya una serie mensual para cada tipo de viajero presente en el conjunto de datos (por ejemplo, Turista, Excursionista, etc.). En total deberá obtener una serie por cada categoría existente.

Nota: El criterio para determinar los tres países, tres regiones y las tres fronteras principales deberá basarse en el **total acumulado de viajeros durante todo el período analizado**, no en un año específico.

4. Análisis de cada serie. Para cada serie:

- a. Especifique Inicio, fin, y frecuencia.
- b. Haga un gráfico de la serie y explique qué información puede obtener a primera vista.
- c. Descomponga la serie. Teniendo en cuenta el diagrama de la serie y sus componentes discuta si es posible hablar de estacionariedad en media y en varianza.
- d. Determine si es necesario transformar la serie. Explique.
- e. Explique si no es estacionaria en media. Para esto:
 - i. Haga el gráfico de autocorrelación y úselo para explicar la no estacionariedad en media.
 - ii. Básese en los valores de estadísticos como la prueba de Dickey-Fuller Aumentada para corroborar la no estacionariedad en media. ¿Qué es necesario hacer para hacerla estacionaria en media en caso de que no lo sea?
- f. Una vez analizada la serie, elija los parámetros p , q y d del modelo ARMA o ARIMA que utilizará para predecir. Explique en qué se basó para darle valor a estos parámetros, teniendo en cuenta las funciones de autocorrelación y autocorrelación parcial. Si usa la función *autoarima* de R o *auto_arima* del módulo *pmdarima* de python, determine y explique si tiene sentido el modelo propuesto.
- g. Haga varios modelos ARIMA, y diga cuál es el mejor de ellos para estimar los datos de la serie. Para esto analice los residuos y las métricas AIC y/ BIC.
- h. Haga un modelo usando cada uno de los siguientes algoritmos: prophet de Facebook, holt-winters, suavizamiento exponencial o seasonal naive. Compárelo con los modelos del inciso anterior. ¿Cuál funcionó mejor?
- i. Haga una predicción de los valores de la serie con el mejor modelo para el conjunto de pruebas.
- j. Compare los modelos mediante MAE (Mean Absolute Error), RMSE (Root Mean Square Error) para ARIMA, AIC y BIC.
- k. Seleccione el mejor modelo teniendo en cuenta las métricas.

5. Análisis comparativo. Responda con evidencia estadística:

- a. Para cada categoría seleccionada:

- i. ¿Cuál de las series presenta mayor estacionalidad?
 - ii. ¿Cuál presenta mayor tendencia de crecimiento?
 - iii. ¿Cuál presenta mayor volatilidad?
 - iv. ¿Cuál fue la más afectada por la pandemia?
- b. En general:
 - i. ¿Qué descubrimientos de los que hizo al analizar las series cree que serían más útiles para que el INGUAT pueda tomar decisiones?

EVALUACIÓN

NOTA: La evaluación de cada integrante del grupo será de acuerdo con sus contribuciones al trabajo grupal

(15 puntos) Análisis exploratorio:

- Se elaboró un análisis exploratorio en el que se explican los cruces de variables, hay gráficos explicativos y análisis que permiten comprender el conjunto de datos.
- Se crearon las series de tiempo correspondientes a las instrucciones.
- Para cada una de las series se informa inicio, fin y frecuencia.
- Se explora el comportamiento de la serie durante y después de la pandemia.

(15 puntos) Análisis de las series de tiempo

- Para cada una de las series creadas se analiza:
 - o El gráfico de la serie y sus componentes.
 - o Si la serie presenta estacionalidad o no y que implica que sí tenga.
 - o Si la serie presenta tendencia o no y esto que significa.

(20 puntos) Determinación de Estacionariedad.

- Para cada una de las series creadas:
 - o Se analiza si es estacionaria en varianza y en caso de no serlo se aplica una transformación adecuada.
 - o Se analiza si es estacionaria en media, para esto se basa en la función de autocorrelación y en la prueba de Dickey-Fuller aumentada. Se determina la cantidad de diferenciaciones que hay que hacer en caso de que no sea estacionaria en media.

(20 puntos) Generación de modelos

- Para cada una de las series creadas:
 - o Se determinan los valores de los parámetros p, q, y d. Para esto se basa en las funciones de autocorrelación y autocorrelación parcial.
 - o Se explica la elección de los parámetros y de los modelos. Se deben explicar los parámetros, aunque sean propuestos de forma automática por R (en caso de usar este lenguaje) o python.
 - o Se generan los modelos con los algoritmos prophet, holt winters, suavizamiento exponencial y seasonal naive.
 - o Se comparan los modelos de acuerdo con el comportamiento de los residuos, las métricas de error y las métricas AIC y BIC.

(15 puntos) Predicción con los modelos generados.

- Para cada una de las series creadas:
 - o Se crean los conjuntos de entrenamiento y prueba siguiendo las instrucciones.

- Se explica que tan bueno es el modelo prediciendo los volúmenes de entrada migratoria para el conjunto de prueba.
- Se comparan los modelos generados con los diferentes algoritmos.

(15 puntos) Análisis comparativo.

- Para categoría seleccionada
 - Se responden las preguntas planteadas y las respuestas con claras y están basadas en evidencia estadística y gráfica.
- En general
 - Se plantean varios descubrimientos basados en los análisis realizados que pueden servirle a INGUAT para toma de decisiones.

MATERIAL A ENTREGAR

- Archivo .pdf con el informe que contenga, los resultados de los análisis y las explicaciones (No se aceptará código en el informe).
- Script de R (.r o .rmd) o de Python que utilizó para hacer su análisis exploratorio y predicciones.
- Link del repositorio usado para versionar el código.

FECHAS DE ENTREGA

- 23 de julio de 2026 17:20:
 - .1. [Avances] Análisis Exploratorio, análisis de al menos dos de las series de tiempo seleccionadas.
- 26 de julio de 2026 23:59
 - .1. Documento completo con todos los análisis.
 - .2. Archivos de código.

NOTA: Para poder tener nota completa debe entregar las asignaciones en el tiempo adecuado. No se calificará el laboratorio si no fue entregado el avance en tiempo, aunque esté en el repositorio.